

LLM講義2025 最終課題 詳細資料

2025/01/25 更新

改變履歷

[illegible]

1. 目的

これまで講義で学んできた知識・スキルを活かし、Struct-EvalおよびAgentBenchと呼ばれるベンチマークスコアを競うローカルLLM(データ・推論が全てローカルで完結するモデル)を開発していただきます。本コンペティションは、受講生全員が参加するメインコンペと、より高度な課題に挑みたい方向けのアドバンスドコンペの2トラック構成となっています。

メインコンペ

講義で学んできた知識・スキルを活かし、LLM講座応用編の最後を飾るに相応しいコンペです
想定レベル: LLMを学びたての方から上級者の方まで

アドバンスドコンペ

より「エージェントらしさ」を追求する、より難易度の高いコンペです
想定レベル: ある程度知識やスキルを積んだLLM中上級者向け

各コンペで優秀なモデルを開発された方には「優秀賞」として表彰もございます

また、スコアだけでなくコミュニティへの貢献も評価し、有益な情報を共有して他の受講生から高い評価を得た参加者を「コントリビューション部門」として表彰します

2. 背景

エージェントとは、LLMを「環境の観測→行動→結果の反映」を繰り返して目的を達成するシステムとして用いる枠組みです。重要なのは質問応答の出来だけでなく、途中で何を観測し、どのように考え・計画し、どんなアクションを選択したかというプロセス全体です。

今回メインコンペに用いるStructEvalというベンチマークは、LLMがソフトウェア開発や業務ワークフローに組み込まれるにつれ、JSON/YAML/CSVのような構造化データを仕様どおりに生成できることが重要である、という問題意識から提案されています。しかし、このような構造化出力の評価は「自然言語の良さ(文章の自然さ)」の評価より難しく、形式ごとの構文・階層・制約に加えて、レンダリング形式では表示結果の妥当性も絡みます。StructEvalはこの難しさに対し、

- ・非レンダリング形式(JSON/YAML/CSV等)とレンダリング形式(HTML/React/SVG等)を横断すること
 - ・自然言語→構造(generation)と構造↔構造(conversion)の2つのパラダイムを用いること
- というアプローチで、18フォーマット・44タスクタイプを包括的に評価可能です。

また、エージェントが環境に働きかけるとき、行動は構造化されたインタフェースで表現されることが多いです。典型例がツール呼び出し(function calling/tool calling)であり、ツール定義や引数がJSON Schema等で規定されるため、モデルがそれに沿った構造(引数オブジェクト等)を安定して出力する必要があります。したがって、StructEvalで試される構造化出力の忠実性は、現代のAIエージェントに必要な基礎能力の一つと言えます。

アドバンスドコンペに用いるAgentBenchというベンチマークは、インタラクティブな8つの環境をCode/Game/Webの3系統に分類し、OS・DB・Knowledge Graph、推理・ゲーム、Web Shopping/Web Browsingなど、実利用に近い多様な環境での自律行動を想定したベンチマークです。ここで重要なのは、単に会話で答える能力ではなく、外部環境を操作してタスクを完遂するエージェントとして、どれだけ上手く振る舞えるかです。1回の回答で終わらないマルチターンの対話的なやり取りの中で、観測に基づく推論と意思決定を行い、行動の積み重ねによって目標を達成できるかを評価します。つまり、環境の観測→行動→結果の反映→再計画...を繰り返す、まさにエージェントらしいタスクになっています。

今回のLLM最終課題コンペでは、これらをコンペ向けに修正したり、リサイズしたのになります。詳細はこの後のルールをお読みください。

3. 講座修了との関連

メインコンペの提出スコアや提出物は他の講義の出席や宿題同様、講座の修了要件に関わりますので修了を目指す方はメインコンペへの参加をお願いします。

アドバンスドコンペの提出やスコアは修了要件には関わりませんので、参加は任意です

4. 参加者

個人で開発してください。全体を通してOmnicampusのアカウントで管理します。後述するSlackの専門チャンネルでの情報共有を除き、複数人が協力してデータの作成やモデルの開発、タスクの生成をすることは禁止します。提出物を確認してこの違反が疑われる場合には開発工程を確認し、成果物の提出を無効にすることがあります。

5. 参加方法・参加条件

メインコンペに関しては参加方法や条件はありません。講座の修了を目指す方は全員参加するようお願いします。

参加フォームなどありませんので、採点にサブミットされた方は参加とみなされます。アドバンスドコンペに関しては、参加条件があります。詳細はアドバンスドコンペルール_参加条件を参照ください。

ここからはメイン・アドバンスドコンペのルールについて説明していきます。

本資料に記載がない事項については、必要に応じて運営に問い合わせてください。(問合せフォーム)

本コンペにおけるLLMの定義は、出力が言語のモデル全般とし、言語モデルであっても出力が言語でなければLLMには含まないものとします。

記載されている禁止事項を遵守していないと運営が判断した場合には、未提出と同等として扱いますのでご注意ください。

6.メインコンペルール

メインコンペに係るルールになります。よく確認いただき参加するようお願いします。

Google Colabの無料プラン(T4 GPU)で実行可能な範囲になっており、計算資源に限りがある方、LLMを学びたての方などにおすすめです。

6.1 メインコンペルール_修了要件

メインコンペのスコアや提出物は他の講義の出席や宿題同様、講座の修了要件に関わります。講座修了を目指される方は運営が公表する基準点(コンペ開始後に公開)以上を取るようモデルの開発・改善を行い、提出をお願いします。

なお、Omnicampusのリーダーボードのスコアは提出の度に上書きとなり、最高点が常に表示されるわけではありません。ですが、DB上で受講生の過去のスコアは保持されているので、過去に出した最高点が基準点を超えていればOKです。(1度でも最高点が基準点を超えたことがあればOKです)

注意

- **基準点を超えたかどうかの個別の問合せには対応しませんので、覚えておくようお願いします。**
 - 過去の採点履歴を受講生側で見れるように対応予定ですが、保証するものではないので覚えておくようお願いします。
- あくまでも修了要件の1つです。必要条件であり、十分条件ではありません。
 - 講義への出席や宿題の結果も加味して決定します。
- 基準点はこちらで提供するサンプルコードをパラメータの変更等で適切に改変を加えて実行できればクリアできる水準です。

6.2 メインコンペルール_コンペの評価

メインコンペでは開発したモデルを用いて生成したjsonファイルをOmnicampus上で提出すると、スコアが自動採点されます。採点結果は定期的にリーダーボードに反映され、Omnicampus上で確認可能です。

最終的なスコアはコンペ終了のタイミングで別途計算され順位が決まります。評価の詳細はコンペ終了後、ランキング発表時に公開する予定です。

締切間近はアクセス集中でエラーが出ることがありますので、余裕を持った提出を推奨します。
提出回数は最大で50回(予定)としますので、計画的な提出を推奨します。

6.3 メインコンペルール_ベンチマークの紹介

メインコンペでは、Struct Eval というベンチマークを一部改変した独自ベンチマークによる評価を行います。

Struct Evalは、LLMにおける、構造化された出力を生成する能力を計るベンチマークです。

例: 「これをjson形式で出力して」「json形式をyaml形式に変換して」など

Struct Evalベンチマークは、大きく分けて2つの評価セットで構築されています。

- Struct Eval - T: テキスト生成を測る
- Struct Eval - V: 上記に加えて、 レンダリングしたものの視覚的な評価も行う

今回のコンペでは、Struct Eval - Tのみを対象として評価を行います。

LLMがコンピュータシステムやソフトウェア開発のAIエージェントワークフローにおいて、エラーなく動作する正確な構造データを生成できるかを試します。

Struct Eval - Tのタスク例: json生成タスク

例えば以下のようなプロンプトが与えられます

...

Please output JSON code.

Task:

Summarize metadata about a fictional scientific article.

Feature Requirements:

1. Top-level field "title" is a string
2. Field "authors" is a list of exactly two items
3. Each author has "name" and "affiliation"
4. Field "publication.year" is an integer
5. Field "keywords" is a list of strings

...

これを受け取ったモデルは、以下のような出力が期待されます。

...

```
{
  "title": "Temporal Anomalies in Sub-Atomic Particle Acceleration: A Case Study",
  "authors": [
    {
      "name": "Dr. Aris Thorne",
      "affiliation": "Institute of Theoretical Chronophysics, Zurich"
    },
    {
      "name": "Prof. Elena Voshkova",
      "affiliation": "Department of High Energy Physics, MIT"
    }
  ],
  "publication": {
    "year": 2028
  },
  "keywords": [
    "Chronophysics",
    "Particle Acceleration",
    "Temporal Dilution",
    "Quantum Mechanics"
  ]
}
```

...

これに対して、JSONの仕様に沿っているかを判定する為の、以下のような採点基準がタスク毎にあります。

```
“raw_ouptut_metric”:{
    “title”,
    “authors[0].name”,
    “authors[1].affiliation”,
    “publication.year”,
    “keywords[2]”
}
```

これは以下のように考えます。

- title: トップレベルにtitleがあるからOK
- authors[0].name: authorsの0番目にnameがあるからOK
- authors[1].affiliation: authorsの1番目にaffiliationがあるからOK
- publication.year: ネストされたpublicationの中にyearがあるからOK
- keywords[2]: Keyword配列に3つ目の要素があるからOK
- ※入っている値は何でも良い

実際の評価データは以下ようになっており、**row_output_metric**が上で説明した採点基準の部分になります。

評価データの一例

```
[
  {
    "task_id": "000500",
    "query": "Please output JSON code:\n\nTask:\n...",
    "feature_requirements": "",
    "task_name": "Text to JSON",
    "input_type": "Text",
    "output_type": "JSON",
    "query_example": "",
    "VQA": [],
    "raw_output_metric": [
      "novel.title",
      "novel.author.name",
      "novel.characters[0].name"
    ],
    "rendering": false
  }
]
```

それに対する推論は以下のようになっています。

推論結果の一例

```
[
  {
    "task_id": "000500",
    "query": "Please output JSON code:\n\nTask:\n...",
    "feature_requirements": "",
    "task_name": "Text to JSON",
    "input_type": "Text",
    "output_type": "JSON",
    "query_example": "",
    "VQA": [],
    "raw_output_metric": [...],
    "rendering": false,
    "generation": ""`json\n{\n  \novel\`: {\n    \title\`: \The Obsidian Labyrinth\`,\n    \author
```

LLMによる推論結果が”generation”として付与されており、この生成結果に対して、

- (この例では)JSONとしてパースできるか
- row_output_metric の採点基準をどれだけ満たしているか

で評価されます。

ただし、これはStructEval-Tオリジナルの評価データや評価方式であり、本コンペでは以下のような工夫を加えています。

- row_output_metricを評価データからは分からないようにしている
 - 評価システム(Omniキャンパス)にtask_idと紐づけて埋め込んでいる
- 各タスクのrow_output_metricを変更している(採点基準を変えている)

本コンペにおいては、採点基準をコンペ参加者側から見えないようにし、さらに、採点基準自体を変更しています。

これにより、コンペ参加者が評価データの採点基準に特化した学習を行うことができないようになっています。(そもその話として、評価データを強く意識した学習はやめましょう)

その他にも

- 評価方法、アルゴリズムも概ねオリジナルと同じですが、コンペ用に一部変更を加えてます。
- コンペで使用する総合点については、形式毎の評価点を平均し、独自の重みづけを行って算出しています。

※このため、オリジナルのStruct Evalを回した場合と採点結果に多少差異が出るので注意してください。

※評価の詳細は非公開とします。

学習のヒント

タスクの形式は、

- TEXT to ○○: 自然言語文の指示から、特定の形式を出力させる (生成タスク)
 - 先ほど説明したタスク例はこちら
- ○○ to XX: 特定の形式から、特定の形式へ変換させる (変換タスク)

の2パターンです。

また、扱う形式は、次の5種類です

- JSON
- YAML
- TOML
- XML
- CSV

本コンペでは、「指定された出力形式」で、「正しい構造を安定して生成する能力」を評価します。
よって、構文を壊さない、要求されたキーを落とさない、余計な文章を出さない（コードだけ出すのが安全）ことを意識して、取り組んでください

6.4 メインコンペルール_提出物

参加者が提出するものは以下の2つです.

1. 運営が提供する推論コードを用いて出力したJSONファイル
2. Hugging Faceにアップロードした, ご自身で開発したモデルのURL
 - a. 運営がモデルを使用できるようpublicにすること.
 - b. READMEも記載してください.

1,2両方とも、Omnicampusの提出ページより提出してください.

タスクの入力であるjsonファイル(評価データ : public_150.json)は以下のような形式を含むファイルになっています.

```
[
  {
    "task_id": "p_7b3394e21698627665533715",
    "task_name": "Text to JSON",
    "rendering": false,
    "query": "Please output JSON code:\n\nTask:\nSummarize a fictional ecosystem with detailed information about its climate, species,
    "output_type": "JSON"
  },

```

運営が提供する推論コードを用いると出力として以下のようなjsonファイルが出力されます.
対応するtask_idに対して推論結果が”generation”として生成されています.

```
{
  "task_id": "p_7b3394e21698627665533715",
  "generation": "{\n  \"ecosystem\": {\n    \"name\": \"Luminara Tundra Ecosystem\", \n    \"location\": {\n
```

こちら(inference.json というファイル名)を提出してください.
念のため、推論結果をDLした後、データを確認してみることをお勧めします.

提出物について、以下の点に注意してください

- 推論(提出物の作成)は運営が提供する標準コードを使用してください。
 - 推論に用いるモデルはHuggingFaceへアップロードした、ご自身で開発したモデル(モデルの制約については後述)にしてください
- 推論コードにより作成された提出物(inference.json)を編集することは禁止です。(以下例)
 - ChatGPTなどのサービスや、APIを使用して編集する。
 - 人手で確認して編集する。
 - などを行い、スコアを上げようとししないでください。
- 開発したモデルはOmniacampusではなくHugging Faceにアップロードしてください。
 - その際、モデルの公開設定をPublicにしてください。
- READMEは運営からの配布物としてサンプルを提示するので、それに倣い記載してください

6.5 メインコンペルール_運営からの配布物

配布時期はメインコンペスタート時になります

- 評価用データ
 - ファイル名: public_150.json
 - 学習に使用しないでください
 - コンペ初めての方は、補足資料「LLMモデル開発におけるお約束」も参照ください
 - 改変も行わないでください。人手、ツール、LLM、一切の手入力を禁じます。
- 標準コード
 - モデルの学習コード
 - ファイル名:
 - 2026最終課題メインコンペ_標準コード1 (SFT) .ipynb
 - 2026最終課題予選_標準コード3 (DPO).ipynb
 - こちらは改変自由です。
 - HuggingFaceのWRITE権限が必要になります
 - HuggingFace READMEのサンプルを含んでいます。
 - READMEを記載するセルがあるので、参考にして記載してください。
 - モデルの推論コード(推論コード)
 - 2026最終課題メインコンペ_標準コード2 (提出JSON生成) .ipynb
 - こちらはモデルの情報以外を一切改変せず利用してください。
 - なので、推論時に動くRAGやToolUseや外部サービスとの連携の類はすべて禁止です。
 - こちらで提出物jsonファイル(inference.json)が作成されます
- 学習用データまとめ
 - 運営作成の合成データ
 - その他、ライセンスOKなデータセットを紹介予定
 - ※これらはスコアが確実に上がることを保証するものではありません。

6.6 メインコンペルール_モデル関連

開発するモデルに係る制約事項は以下です。

- 本コンペにおける学習指定モデルは以下です
 - Qwen/Qwen3-4B-Instruct-2507
 - unsloth/Qwen3-4B-Instruct-2507
 - これ以外のモデルの使用は認めません。派生モデルも禁止です。
- 提出するモデルは学習指定モデルを学習したモデルであること。
 - モデルアーキテクチャの変更は認めません。
- 提出するモデルはHugging Faceにモデルとしてアップロード可能であること
 - WRITE権限のキーが必要になります。取得方法は補足資料> HuggingFace のトークン取得方法を確認ください
- 提出するモデルには必ず何かしらの変更を加える必要があります
 - SFTやRLHF、DPOなどによりパラメータを更新すればその条件を満たします
 - 量子化も変更にあたります
- モデル開発のあらゆる段階でStructEvalのデータを用いることを禁止します。
 - 運営が提供する評価データは勿論、オリジナルのStructEvalのデータを用いることも禁止
- リーダーボードを利用したチューニングを禁止します。

6.6 メインコンペルール_学習データ関連

モデルの学習に用いるデータに係る制約事項は以下です。

- 運営が提供、または紹介する学習データ以外の使用は禁止です
 - 運営が提供する、または紹介するデータの範囲で学習を行ってください。
- **LLMを用いたデータの作成は禁止です**
 - 運営が提供、または紹介するデータをLLMを用いて改変したり、合成することは禁止です。
- **LLMを用いないデータ作成は可とします**
 - 詳細は補足資料をご確認ください。
 - 補足資料> LLMモデル開発におけるお約束
 - 補足資料> LLMによるデータ作成
 - 例えば、運営が提供する、または紹介するデータをLLMを用いず改変することは可能です。

7. アドバンスドコンペルール

アドバンスドコンペに係るルールになります。よく確認いただき参加するようお願いします。
参加は任意です。メインコンペより自由なルールで取り組んでいただける上級者向けのコンペになっており、難易度も高いため参加される際はその点留意ください。

また、アドバンスドコンペは優秀賞の選出にも関わりますので、優秀賞を目指される方は積極的にアドバンスドコンペに参加してください。

7.1 アドバンスドコンペルール_参加条件

アドバンスドコンペには参加条件があります。
2026/02/04(水) 23:59 までに[Googleフォーム](#)から参加申請を行ってください。
※参加フォームは2026/01/28(水)のコンペ説明会後にオープン予定です。

2026/02/08(日) 17:00 時点での[メインコンペにおける提出物の提出履歴に基づき、参加フォームに申請された方の中からアドバンスドコンペ進出者を選出します。\(最大200名を想定しています\)](#)
進出された方にはアドバンスドコンペの開発環境がオープンされます。
メインコンペに積極的に参加いただき、良いモデルを開発するようお願いします。

サブミットページはアドバンスドコンペ進出者の方のみ使用するようお願いします。

7.2 アドバンスドコンペルール_コンペの評価

アドバンスドコンペでは開発したモデルをOmnicampusのバックエンド環境にて走らせて、評価プログラムを用いて暫定的なスコアを自動採点します。採点結果は定期的にリーダーボードに反映され、Omnicampus上で確認可能です。

リーダーボードの採点は暫定的なものであり、最終的なスコアはコンペ終了のタイミングで別途計算され順位が決まります。評価の詳細はコンペ終了後、ランキング発表時に公開する予定です。

最大で20回(予定)まで提出できます。回数が制限されているため、計画的な提出を推奨します。
締切間近はアクセス集中でエラーが出ることがありますので、余裕を持った提出を推奨します。

採点システムとサブミットに関するお願い

本採点システムはGPUインスタンスを利用する都合、以下のような採点失敗が想定されます。

1. 採点時のGPUリソース確保失敗
2. 採点中のエラー
3. 採点時間(後述)超過

恐縮ですが、1番目につきましては時間を空ける、2,3番目につきましては、開発環境などを用いて推論が回るか、実行時間は大丈夫かなどの事前検証を入念に行っていただくようお願いいたします。

また、採点システムにおける評価は以下のように行われます

1. 提出されたモデル情報を用いてvllmのDockerコンテナを立ち上げ
2. 推論

1,2含めて採点実行時間となります。

採点エラー時について

システムの仕様上、エラーや採点時間(後述)超過となった場合でもサブミット回数が消化されてしまいます。 恐縮ですが、開発環境などを用いて推論が回るか、実行時間(vllmの立ち上げ時間も含めて)は大丈夫かなどの事前検証を入念に行っていただくようお願い致します。

採点時間の制限について

1回の採点には**2時間20分(予定)のタイムリミット**を設けています。これを超過すると「採点失敗」となります。

サブミットが開始されてからのカウントになります。

参考: 学習指定モデル(未学習・手付かずの状態)での採点実行時間は、最大で1時間40分弱です。

円滑な運営へのご協力をお願い

限られた計算資源を全参加者で共有しているため、インフラへの負荷分散にご協力いただけると幸いです。

目安として**1日4回程度のサブミット**を心がけていただけますと、システムが安定し、結果として皆様の採点待ち時間が短縮されます。

終了間際のトラブルについて

コンペ終了直前など、アクセス集中の影響でサブミットが失敗した場合、ログや過去の利用状況(無理な連投がないか等)を確認の上、個別に救済措置を検討させていただきます。

安定運用にご協力いただいた方を優先的にサポートいたしますので、何卒よろしくお願いいたします。

採点インフラを皆様に安定的にご利用いただくため、以上の点についてご理解とご協力をお願いいたします。

7.3 アドバンスドコンペルール_ベンチマークの紹介

アドバンスドコンペでは、AgentBench というベンチマークを用います。

OS操作、DB操作、オンラインショッピング,推論パズルなど、実世界を模した8つの多様なインタラクティブ環境を構築し、モデルが与えられたタスクを解くベンチマークです。

例:

- 家の中で「探す→拾う→きれいにする→置く」といった一連の物理的行動を計画・実行する
- 質問に対し、実際にSQLを実行して答える

今回はその内2つのタスクを採用し、総合点で勝負します

(※総合点の出し方は論文を踏襲。他の情報は最終結果発表時に発表)

- DB Bench:
 - テーブル情報と要求を受け取り、適切なクエリを組み立ててDBを操作するタスク
 - 150問 (コンペの都合上減らしています)
- ALFWorld:
 - 環境描写 + タスク目標を受け取り、目標を達成する行動を出力するタスク
 - 50問

LLMが与えられた指示に対して行動し、環境とインタラクションすることで行動を改善し、最終的に期待される応えを得ることができるかというエージェントの能力を試します。

タスク例 DB Bench:

エージェント(LLM) はシステムから以下のようなプロンプトを受け取ります。
エージェントの記述スタイルなどの指示と、問題文と、テーブルの情報です。

User:

I will ask you a question, then you should help me operate a MySQL database with SQL to answer the question.

You have to explain the problem and your solution to me and write down your thoughts.

After thinking and explaining thoroughly, every round you can choose to operate or to answer.

your operation should be like this:

Action: Operation

““sql

SELECT * FROM table WHERE condition;

““

You MUST put SQL in markdown format without any other comments. Your SQL should be in one line.

Every time you can only execute one SQL statement. I will only execute the statement in the first SQL code block. Every time you write a SQL , I will execute it and answer.

Your answer should be accurate. Your answer must be exactly the same as the correct answer.

If the question is about modifying the database, then after done operation, your answer field can be anything.

If your response cannot match any pattern I mentioned earlier, you will be judged as FAIL immediately.

Your input will be raw MySQL response, you have to deal with it by yourself it for you and give you the output.

If you are done operating, and you want to commit your final answer, then

write down:

Action: Answer

Final Answer: ["ANSWER1", "ANSWER2", ...]

DO NOT write this pattern unless you are sure about your answer. I expect an accurate and correct answer.

質問内容

Question: What is the Presentation of Credentials has a Termination of Mission listed as August 15, 2000?

テーブル情報

The name of this table is US Ambassadors and Envoy Extraordinary to Colombia, and the headers are Representative (TEXT), Title (TEXT), Presentation of Credentials (TEXT), Termination of Mission (TEXT), Appointed by (TEXT).

これに対してエージェントは、どのような考え方をするかとクエリを組み立てます。エージェントの回答例が以下です。

Agent:

The question asks me to find the "Presentation of Credentials" value for the row where "Termination of Mission" is "August 15, 2000".

This is a simple SELECT query with a WHERE clause filtering by the Termination of Mission column.

Action: Operation

```
```sql
```

```
SELECT `Presentation of Credentials` FROM `US Ambassadors and Envoy Extraordinary to Colombia`
WHERE `Termination of Mission` = 'August 15, 2000';
```

```
```
```

このエージェントの回答に対して、システム側はクエリを実行します。クエリの実行結果をエージェントに返します。

```
+-----+  
| Presentation of Credentials |  
+-----+  
| March 19, 1998 |  
+-----+
```

この結果を受け取り、エージェントは回答を作成します。

Agent:

The query returned "March 19, 1998" as the Presentation of Credentials for the ambassador whose Termination of Mission was August 15, 2000.

Action: Answer

Final Answer: ["March 19, 1998"]

このFinal Answerの値がタスクの正解ラベルと一致していれば正解となります。

このサンプルは説明の為、1往復になってますが、実際はエージェントが間違えたクエリを組み立てたり、することで、システムから返ってくるクエリ結果を元に自己修正を繰り返し回答にたどり着けるか、という内容になります。

タスク例 ALF World:

エージェント(LLM) はシステムから以下のようなプロンプトを受け取ります。
エージェントの記述スタイルなどの指示や注意についてです。

User:

Interact with a household to solve a task. Imagine you are an intelligent agent in a household environment and your target is to perform actions to complete the task goal. At the beginning of your interactions, you will be given the detailed description of the current environment and your goal to accomplish. For each of your turn, you will be given a list of actions which you can choose one to perform in this turn. You should choose from two actions: "THOUGHT" or "ACTION". If you choose "THOUGHT", you should first think about the current condition and plan for your future actions, and then output your action in this turn. Your output must strictly follow this format: "THOUGHT: your thoughts.

ACTION: your next action

"; If you choose "ACTION", you should directly output the action in this turn. Your output must strictly follow this format:"

ACTION: your next action

". After your each turn, the environment will give you immediate feedback based on which you plan your next few steps. if the environment output "Nothing happened", that means the previous action is invalid and you should try more options.

Reminder:

1. the action must be chosen from the given available actions. Any actions except provided available actions will be regarded as illegal.
2. Think when necessary, try to act directly more in the process.

これをもとに、例えば以下のようなタスクをシステムから受け取ります。
環境の情報と、達成すべき目標と、可能なアクション一覧です。

User:

今置かれている環境

Here is your task. You are in the middle of a room. Looking quickly around you, you see a bathtubbasin 1, a cabinet 2, a cabinet 1, a countertop 1, a garbagecan 1, a handtowelholder 1, a sinkbasin 1, a toilet 1, a toiletpaperhanger 1, and a towelholder 1.

エージェントのタスク

Your task is to: put some soapbottle on garbagecan.

現在取れる行動一覧

AVAILABLE ACTIONS:

go to bathtubbasin 1

go to cabinet 1

go to cabinet 2

go to countertop 1

go to garbagecan 1

go to handtowelholder 1

go to sinkbasin 1

go to toilet 1

go to toiletpaperhanger 1
go to towelholder 1

以降は、システムとインタラクションし、エージェントがアクション→システムがその結果を回答→...を繰り返す、目標を達成できるよう繰り返します。
以下が例です。

Agent:
思考
THOUGHT: I need to find a soapbottle and put it on garbagecan. I'll start searching in cabinets since soap items are often stored there.
アクション
ACTION: go to cabinet 1

User:
結果 (キャビネット1が閉まっていた)
The cabinet 1 is closed.
AVAILABLE ACTIONS:
open cabinet 1
go to bathtubbasin 1
go to cabinet 2
go to countertop 1
go to garbagecan 1
go to handtowelholder 1
go to sinkbasin 1
go to toilet 1
go to toiletpaperhanger 1
go to towelholder 1

Agent:
キャビネット1を開ける
ACTION: open cabinet 1

User:
キャビネット1を開けたら、石鹸が入っていた
You open the cabinet 1. The cabinet 1 is open. In it, you see a soapbottle 1.
AVAILABLE ACTIONS:
close cabinet 1
go to bathtubbasin 1
go to cabinet 2
go to countertop 1
go to garbagecan 1
go to handtowelholder 1
go to sinkbasin 1
go to toilet 1
go to toiletpaperhanger 1
go to towelholder 1
石鹸をキャビネット1から取り出す選択肢が与えられた。
take soapbottle 1 from cabinet 1

※実際は、一連のやり取りで正解にたどり着く例が1-shot 例として与えられてからタスクがスタートします。

タスクのイメージ図

| TextWorld | Embodied |
|---|--|
| 
<pre>Welcome!

You are in the middle of the room.
Looking around you, you see
a diningtable, a stove,
a microwave, and a cabinet.

Your task is to:
Put a pan on the diningtable.

> goto the cabinet

You arrive at the cabinet.
The cabinet is closed.

> open the cabinet

The cabinet is empty.</pre> | 

 |

(<https://github.com/alfworld/alfworld> より)

学習のヒント

採点結果に点数のみでなく、各種メトリクスが出るようになっています。それらを見て、どんな学習させるべきか考えられるかもしれません。

7.4 アドバンスドコンペルール_提出物

提出するものは、以下のようなcsvファイルです、

| | A | B |
|---|-----------------------------|----------|
| 1 | model_path | hf_token |
| 2 | Qwen/Qwen3-4B-Instruct-2507 | hf_qtnr |
| 3 | | |

A1,B1はテンプレートのまま編集せず、A2にHuggingFaceのモデルパス、B2にご自身の**READ権限付きトークン**を記載してください、(評価時におけるレートリミット回避のためにREAD権限が必要になります)
READ権限の取得の仕方は補足資料を確認してください、

- また、以下の点に注意してください
- モデルパスはHuggingFaceから取得できるものにしてください、
 - モデルのページにREADMEも記載してください、
 - 運営がサンプルを提示するので、それに倣い記載してください
 - モデルの公開設定はPublicにしてください、

7.5 アドバンスドコンペルール_運営からの配布物

配布時期はアドバンスドコンペスタート時を予定しています

※予定は予告なく変更の可能性があります、

- 標準コード(モデル学習コード) (予定)
 - 改変自由
 - HuggingFace READMEのサンプル出力セルもセットになります、
- 学習用データ(予定)
 - 運営作成の合成データ
 - その他、ライセンスOKなデータセットを紹介します
 - ※これらはスコアが確実に上がることを保証するものではありません、
- Omniキャンパス環境使用手順書
 - ペンチマークの仕様上、推論コード単体で配布できないため開発環境を配布します、
 - Omniキャンパス開発環境でAgentBenchが動かせる手順書になります、
 - 推論実行のサンプルとしてご利用ください、
 - どのような開発環境かは「提供開発環境」の項を確認ください、
- モデルホワイトリスト
 - 学習指定モデル(後述)以外に、合成や蒸留に使用してよいモデルのリストになります

※参加者自身の環境(Not開発環境)でAgentBenchを推論できるコードの配布は現在予定しておりません、

7.6 アドバンスドコンペルール_モデル関連

開発するモデルに係る制約は以下です。

- 本コンペにおける、学習指定モデルは以下です
 - Qwen/Qwen2.5-7B-Instruct
 - Qwen/Qwen3-4B-Instruct-2507
 - これ以外のモデルの使用は認めません。派生モデルも禁止です。
- 提出するモデルは学習指定モデルを学習したモデルであること。
 - モデルアーキテクチャの変更は認めません。
- Hugging Faceにモデルとしてアップロード可能であること。
- モデルには必ず何かしらの変更を加える必要があります
 - SFTやRLHF、DPOなどによりパラメータを更新すればその条件を満たします
 - 量子化も変更にあたります
- モデル開発のあらゆる段階でAgentBench、およびALFworldのデータを用いることを禁止
 - このデータを用いた合成データの生成も禁止
- メインコンペのリーダーボードを利用したチューニングもこの行為に含まれます
- 蒸留は利用可能
 - ただし、教師モデルには別途提示するホワイトリストのモデルのみ用いること
 - 最終的に採点するモデルのアーキテクチャは指定モデルと同一であり、かつ指定モデルをベースとしている必要があります。
- 評価環境はL4 GPUインスタンスで稼働しているので、L4 GPU のVRAM 24GBで回らないようなモデルの学習は行わないでください。

※ホワイトリストはアドバンスドコンペ開始時に公開予定です。

本コンペはバックエンドで参加者のモデルをロードし推論を行う都合上、モデルの形式に以下の厳格な指定があります。推論には vLLM の公式 Docker イメージを用い、以下のコマンドで起動します。この環境で動作しないモデルは評価不能となりますので注意してください。

```
```bash
docker run --runtime nvidia --gpus all \
 --ipc=host \
 vllm/vllm-openai:v0.13.0 \
 --model "参加者の提出モデルパス" \
 --max-model-len 8192 \
 --gpu-memory-utilization 0.95
...`
```

### 注意点

- アーキテクチャの変更禁止: 指定モデルのアーキテクチャを変更することは認めません
- トークナイザーの変更制限: 語彙の追加は禁止  
語彙追加に伴い Embedding 層のパラメータサイズが変更されると、vLLM の起動時に形状不一致エラーが発生するリスクが高いため
- アダプター(LoRA等)の扱い:
  - LoRAなどのアダプターを用いる場合は、必ずベースモデルにマージした状態で提出してください。実行時にアダプターを動的にロードする方式は不可とします。
- 量子化:
  - 運営側で --quantization などの起動オプションは付与しません
  - 量子化モデル (AWQ, GPTQ等) を提出する場合は、モデルの config.json に量子化設定 (quantization\_config) が正しく記述されており、vLLM が設定なしで自動認識できる形式 (AutoAWQ / AutoGPTQ 等で保存された形式) である必要があります。
- Chat Template の必須化:
  - OpenAI互換のエンドポイント(<http://localhost:8000/v1/chat/completions>)を使用するため、tokenizer\_config.json に正しい chat\_template が含まれていることを確認してください。

事前に開発環境にてvllmによる推論テストが可能です。推論が回るかなどの確認にご利用ください。

## 7.7 アドバンスドコンペルール\_データ関連

LLMの学習に用いるデータに係る制約は以下です。

- 合成データは利用可能とします。
  - ただし、別途提示するホワイトリストのモデルのみ用いること
    - ホワイトリストモデルに対して量子化を行うのは自由です。
- アドバンスドコンペは自身でライセンス的に問題ないデータを探して学習に使用してOKです
- 運営が提供、または紹介するデータ以外を使う場合は以下の点に気を付けてください
  - 非商用利用に制約のないライセンスのものを使用すること。
  - 許可なく取得、使用してよいと提供元が認めているデータのみを使用すること
  - 運営が問い合わせに対応するのは、運営が提供および紹介したデータに限ります
  - 有料のデータは使用禁止です。
  - 公開(誰もが無償でアクセス可)されていないデータの使用は禁止です。
  - 各種ライセンスの取り扱いには十分注意してください。
- AgentBenchで用いられているデータは勿論、それらを模倣したようなデータは使用しないでください。

## 8. 開発におけるツールの扱いについて

APIやライブラリ、ソフトウェア、外部ツールなどの関しての制約は以下です(メインコンペ・アドバンスドコンペ共通)

記載されている禁止事項を遵守していないと運営が判断した場合には、未提出と同等として扱いますのでご注意ください。

※ 本コンペにおける「LLM」とは、言語を出力とするモデル全般とし、いわゆる言語モデルであっても言語を出力としないものはこれに含まれないものとします。

### 利用可能

- 開発コーディング補助:
  - プログラムコード作成、デバッグ等のために、コーディング支援AI・LLMを使用すること。
  - 例: GitHub Copilot, Cursor, ChatGPT(Web版) 等によるコード生成
  - コーディング補助としてのみ使用すること
    - CodexやClaudeCodeにお願いすればデータの合成などは可能だが、行わないでください
- モデル実行用ライブラリ・ツール:
  - 許可されたモデル(メインコンペは学習指定モデル、アドバンスドコンペは学習指定モデル+ホワイトリストモデル)を動作させるためのライブラリや推論・学習用ツール
    - モデルを推論・学習させたり、合成(※アドバンスドコンペのみ)させることを想定していますが、それ以外にも使っても良いです。
- 非LLM的なデータ処理:
  - 正規表現、形態素解析、Excel操作など、LLMの推論能力に依存しないデータ処理
  - BERT、RoBERTa、DeBERTa等のエンコーダモデルを使ったテキスト処理

### 利用不可・禁止事項

- 主要商用モデルのAPI利用 (OpenAI, Anthropic, Google, etc.)
  - ChatGPT API、Claude API、Gemini API 等の有料・無料を問わず、クローズドな商用モデルのAPIを利用することを禁止します。
- 許可されたモデル(メインコンペは学習指定モデル、アドバンスドコンペは学習指定モデル+ホワイトリストモデル)以外のオープンモデルのAPI利用
  - llama3 など
- 翻訳サービスを用いたデータ合成、拡張の禁止
  - クローズドな翻訳サービスを使ってデータ拡張(英→日→英で表現の水増し等)は禁止

#### ポイント

- LLMモデルに関しては学習指定モデル+ホワイトリストにすべて纏まっているので、それ以外のモデルを使用しない
- 非LLM的な処理(ルールベースは勿論、BERT等のモデルを使用した処理)はOK
- コーディングエージェントはコードを書くことだけのために使用すること
- クローズドなモデルAPIを使わない
- ホワイトリストモデル以外のオープンモデルのAPIも使わないでください。
- 翻訳は母語でない言語を読むためだけに使うこと

#### 注意

- アドバンスドコンペにおけるデータ合成のためにスクレイピングなどを行う場合はrobots.txtやWebサイトの規約などサイト側の指定したルールを順守の上、行ってください。また、個人情報が含まれないよう注意してください。
- ただし各サービスの規約には必ず従ってください。
- 決勝に参加される方は補足資料>データ作成について もご確認ください。

## 9. 提供開発環境

メインコンペ参加者に対しては開発環境の提供はありません。ご自身でGoogleColabの環境などを用意し、開発に取り組んでください。コンペの内容自体はGoogleColab無料枠(T4 GPU)相当で可能な内容になっております。

アドバンスドコンペ参加者に関しましては開発環境を提供します。AgentBenchを推論・評価可能な環境になります。モデル学習に使っていただいても構いません。(モデル学習コードの提供は未定です)

#### 基本スペック

- CPUメモリ: 32GB
- GPU: L4 (24GB)
- ストレージ:
  - 100GBを超えるデータやファイルのダウンロードは控えて下さい。
  - 揮発性のため、永続的にデータを保持したい場合は適宜DLなどをご利用ください。

#### 注意事項

- 参加者側で新しくDockerなどのコンテナを入れることは不可
- 個人でスクリプトなどを書き、快適に使っていただくことは可能ですが、カスタマイズについては運営はフォローいたしません。
- uvやminicondaなどのライブラリやその他コンペルールに抵触しないソフトウェアが利用可能ですが、動作検証はしておりません。運営のサポートはありませんので自己責任でご利用ください
- 演習環境内には推論コードが置かれており、それを実行することで推論時間や出力の確認が可能です。演習環境内での実行のみを想定している事に注意してください。
- **使用時間に制限がございます。GPUの利用量に応じて延べ60時間(予定)まで利用することができません（L4を2枚同時に使用したら消費時間が2倍、4枚同時に使用したら4倍になります）。**

使用方法については別途展開する手順書を確認ください。

## 10. 優秀賞

コンペにおいて優秀な取り組みをされた方には表彰をさせていただきます。

優秀賞の選出条件※は以下です。

- アドバンスドコンペ及びメインコンペのルールが守られている方が対象になります。
- 最終スコアに加えて、提出内容を加味し選出します。
- 開発ドキュメントの提出を了承していただく必要があります。
  - Notion上にモデルの開発手順を説明する開発ドキュメントを提出してもらいます。
  - ※開発ドキュメントの内容は追って連絡します。

※選出条件は変更の可能性がございます

選出部門は以下を予定しています。

- 一般部門
  - アドバンスドコンペから最大20名
- U-29部門
  - アドバンスドコンペまたはメインコンペから最大5名
  - 29歳以下かつ学生(小学生から大学院生まで)に限定
- U-18部門
  - アドバンスドコンペまたはメインコンペから若干名
  - 18歳以下の高校3年生または高専生3年生以下の学生に限定

優秀賞の発表や詳細は最終結果発表会にて発表予定です

## 11. 専用チャンネルでの投稿とコントリビューション賞

### 投稿ルール

- 松尾研LLMコミュニティのSlackにコンペ情報シェア用の専用チャンネルを用意しています。
  - [#12\\_llm2025\\_コンペディスカッション](#)
- こちらでコンペに関する投稿を募集します。
- [LLM講座のNotion](#)上で執筆し、リンクと概要をSlackに投稿してもらうことを想定していますが、厳密なフォーマットは指定しません
- モデルの出力全体を共有することはお控えください。

他の参加者への助言や自分の手法の公開、手法の紹介、奮闘記、コードなど、コンペに関する情報であれば失敗談も含め歓迎です。

受講生の皆さんは良いと思った投稿にぜひ絵文字(💖)を押してください。

また、このような投稿を行い、コンペに貢献された方を称えるコントリビューション賞を用意しています。

## コントリビューション賞ルール

- **専用チャンネルに投稿されたものだけが賞の対象となります。**
- 対象期間はメインコンペ開始時からコンペ終了日の前日までです。
  - 2026/02/02(月) 12:00～2026/03/01(日) 23:59
- メインコンペ・アドバンスコンペ両方の投稿が対象です。
- 対象となる投稿
  - Notionのリンクがない場合、本文のみの投稿が対象となります
  - リプライは対象となりません。
- コンペにおける違反が発覚した場合、その参加者はコントリビューション賞の資格を失います。
- 投稿者が投稿ルールやコントリビューション賞ルールを守れていない場合、コントリビューション賞の対象となりません。

コントリビューション賞の部門は以下の2つです。

### コントリビューション部門賞

以下の条件で最大5名を選出します

- の絵文字を押したユーザー数が上位だったものを対象とする
- 単一ユーザーが複数の投稿をした場合、の数を合算せず、最も数の多い投稿のみを対象とする
- 絵文字はのみをカウントする

### コントリビューション部門特別賞

以下の条件で最大5名選出します。

- 専用チャンネルに投稿された記事のうち、LLM講座の講師陣が高く評価したものを対象とする

モデル開発における知見をシェアし、多くの方に貢献した方を表彰します。  
コントリビューション部門に参加される方は、Slackの専用チャンネルにぜひ投稿してください。  
他の受講生は積極的に絵文字で評価いただけると助かります。

コントリビューション賞の発表や詳細は最終結果発表会にて発表予定です

## 12. スケジュール及び各提出物期限

2026/01/28(水) 21:00~21:30 :

- コンペ説明会開催.
- [Googleフォーム](#)でアドバンスドコンペ参加エントリーを開始

2026/02/02(月) 12:00:

- メインコンペのオープン、及び、修了要件スコア公開
- 運営配布物の展開.
- コントリビューション賞の対象となる専用チャンネルでの記事投稿の受け付けを開始.

2026/02/04(水) 23:59:

- [Googleフォーム](#)でのアドバンスドコンペ参加者受付をクローズ

2026/02/08(日) 17:00:

- この時点における、メインコンペモデル提出状況をもってアドバンスドコンペ進出者を決定します

2026/02/09(月) 12:00:

- アドバンスドコンペのオープン、及び、運営配布物の展開.
- **メインコンペはアドバンスドコンペが始まっても並行して続き、修了要件獲得のために3/2まで引き続き提出は可能です。**

2026/03/01(日) 23:59:

- コントリビューション賞の対象となる専用チャンネルでの記事投稿の受け付けを締切.

2026/03/02(月) 12:00:

- メインコンペ・アドバンスドコンペのクローズ、以降はメインコンペ提出物(jsonファイル、HuggingFaceのURL)、及びアドバンスドコンペ提出物(csv)はサブミットができませんので注意してください.
- 各締切後の提出や差し替え依頼は受け付けませんのでご注意ください.
- **締切間近はアクセス集中でエラーが出ることがありますので、余裕を持った提出を推奨します.**
- **特にアドバンスドコンペは採点が重くなる可能性があるので、早めの採点を推奨します.**

※優秀賞の開発ドキュメント作成依頼に関しては追って連絡します

2026/03 中旬以降:

- 最終結果発表(メインコンペ・アドバンスドコンペ)
- 結果を精査の上、優秀賞を発表します
- コントリビューション賞を発表します.

## 補足

### HuggingFace のトークン（READ / WRITE）取得方法

Hugging Faceに自分のモデルやデータセットを保存したり、設定を変更したりするには、書き込み用の「トークン」が必要です。メインコンペの標準コード内ではモデルのアップロードまで行うため、WRITE権限が必要になります。また、アドバンスドコンペは評価システムを動かすうえでREAD権限が必要になります。

#### 大切な注意点

トークンは「パスワード」と同じです。このトークンが他人に知られると、あなたのリポジトリを勝手に書き換えられてしまう恐れがあります。

GitHubなどにそのまま貼り付けて公開しないよう、十分注意してください。

#### 手順

1. Hugging Face にログイン(<https://huggingface.co/>)
2. 画面右上の自分のアイコンをクリック
3. メニューの中からSettingsを選択
4. 左側のサイドメニューにある「Access Tokens」をクリック
5. 画面中央左寄りにある「+ Create new token」ボタンをクリック
6. 設定ウィンドウが開くので、以下の項目を入力・選択します。
  - a. Token Name: 自分が分かりやすい名前を付けます（例：my-token など）。
  - b. Token type: 目的に合わせてどちらかを選択してください。
    - i. **Read: 読み取り専用**
      1. モデルやデータのダウンロード、非公開リポジトリの閲覧のみを行う場合。
      2. アドバンスドコンペの評価にはこちらを使います。
    - ii. **Write: 書き込み権限**
      1. 自分のモデルをアップロードしたり、リポジトリを編集したりする場合
      2. メインコンペの標準コードではこちらを使います。最後に、下にある「Create token」ボタンを押して完了です。
7. 作成されたトークンの横にある **コピー** をクリックして、トークンをコピー
  - a. コピーした文字列は、メモ帳などに貼り付けて大切に保管してください

### ライセンスについて

※本コンペに限らず、**一般的な社会ルールとして理解しておいてください。**

※本欄では、コンペ参加にあたっての必要最小限の説明に留めます。

詳しく学びたい方は、本項目末尾記載のリファレンスを参照してください。

#### 注意

- 筆者は、法務的なアドバイスを行うための資格を所持していません。

- また、内容の正確性を保証するものではありません。そのため、本欄記載の内容に伴って生じるいかなる損害も補償いたしかねます。

### 1. そもそも「ライセンス」って何？

「ライセンス」＝著作権者が本来持つ排他的な権利の行使を、一定条件のもとで許すルールです。  
一般に「ライセンス」とは、**ある行為をしてよい、という許諾（permission）と、その条件を指します**

知的財産の文脈では、著作物（ソフトウェア、データ、モデル重み等）について、  
「どのように使ってよいか」、「どこまで許されているか」、「何を守らなければならないか」  
を、権利者が明示的に示したものがライセンスです。

### 2. 大原則として、ライセンスが不明なものは使わない

公開モデル・データ・コードの多くは、利用可能範囲を「ライセンス」や「利用規約(Terms)」で示しています。利用前に必ず確認し、不明・曖昧・入手経路が怪しいものは使わない、が安全原則です。  
実務的には、「**ライセンスが書いていないものは、使えない可能性が高い**」と考えましょう。

### 3. コンペ視点で押さえるべき3つのチェックポイント

今回のコンペにおいては、ライセンスに関して次の3点を必ず確認してください。

- **商用利用の可否**  
※今回のコンペでは基本的に関係ありませんが、将来の公開を見据えると重要
- **ライセンス継承義務（コピーレフト）があるか**  
派生物や再配布時に、同じライセンスを引き継ぐ必要があるか
- **学習・蒸留・合成データ生成に使ってよいか**  
ライセンスだけでなく、**利用規約も含めて確認**

### 4. LLM開発において、何にライセンスが付くのか

- コード(学習・推論・評価スクリプト、ライブラリ)  
MIT / Apache-2.0 / BSD / GPL / MPL などのソフトウェアライセンスが適用されます。
- データ(学習データ、評価データ、合成に使用するデータ、収集したURLリスト等)

重要な注意点：

**データセット全体のライセンスと、中身の個々のデータの由来・ライセンスは、必ずしも一致しません。**

**実務でよくあるNG例：データカードの表記だけを信じるのは危険**

データカード上は「CC0」「MIT」「CC BY」などの緩い表記

しかし中身を見るとChatGPT / OpenAI API 等で生成された合成データ

⇒ OpenAI の利用規約では、（限定された例外を除き）**アウトプットを用いて競合するモデルを開発することが原則として禁止されています。**

⇒ つまり（データカードの記載に関わらず）その合成データをLLM開発に使用できません。

- モデル(重み・パラメータ)

例: ベースモデル、微調整後モデルのモデル重み(weights)やチェックポイントなど

ソフトウェアライセンスとは別の「**モデル専用ライセンス**」が適用されることも多いです。

- 出力(生成物):

例: 合成データ、生成文章、ログ、配布物

出力に関する注意点:

生成物自体の著作権とは別に、「出力の使い方」がモデルの利用規約・ライセンスで制限される場合があります。(特に「出力を学習に使う」場合、こう明記しなさい、など)

**特に注意すべき点:**

出力を **学習データ** として再利用してよいか

出力で **他のLLM** を改善してよいか

プロプライエタリモデル (ChatGPT / Gemini 等) では、

**生成データを競合モデルの作成に使うことに制約がある場合があります。**

## 5. ライセンスの伝播性

LLM開発において、ライセンスの影響が次の2系統から来ることが多いです。

- 著作権ライセンス由来の制約
  - GPL/AGPL/MPL
  - CC BY-SA
- 利用規約・契約・ポリシー由来の制約
  - 派生モデルへの規約継承義務
  - 表示義務
  - 学習・蒸留の禁止事項

**LLMを使って合成データを生成した場合、ソフトウェアライセンスのコピーレフトがそのままデータに自動継承されるとは限りません。**一方で、**モデルの 利用規約や追加条項 (AUP / Terms) によって、出力の再利用方法や学習への利用が制限されることは十分にあり得ます。**

結論として、生成に使用したモデルの「**ライセンス+利用規約**」を必ず両方確認してください。

## 6. 有名なライセンスの一覧

コピーレフト無し

- MIT
- Apache 2.0
- BSD-2, BSD-3

コピーレフトあり

- GPLv3
- AGPL
- MPL-2.0
- CC BY-SA (※主に、文書・データ向けのライセンス)

モデル・重み向けライセンス (独自条項が多い)

- Llama 3.1 community license
- Qwen license

## 7. まとめ

- 使用するツール、モデル、データそれぞれのライセンス／利用規約を必ず確認しましょう
- 複数のコピーレフトライセンスが関わっている場合、互換性がない組み合わせは配布不能になる可能性があります。その場合、組み合わせを回避／代替素材を探す、等の対応が必要です。
- コンペの実務的には...
  - 今回のホワイトリストモデルにおいては、合成や蒸留に使えるよう比較的ライセンスが緩いものを選定しています。
  - ただし、**ご自身でデータを追加する際には十分気を付けてください**
  - HuggingFaceのモデル／データセットには、ページ上にライセンス情報が表示されていますので、必ず確認してください。

## 参考

- ・ AIとライセンス・著作権・法制度（NII 小田悠介先生の講演） <https://youtu.be/5AIX1SwhJsY>
- ・ LLM講座2025 基礎編 Day8 資料にライセンスについての補足資料があります。

## データ作成について

LLMコンペを開催していると、データ合成についての許可・禁止の話を行う際に、「どこからがLLMによるデータ合成ですか?」「この手法はデータ合成に該当しますか?」などといった質問をよく受け付けます。以下に例を挙げるので「これはLLMによるデータ合成、これはLLM以外の技術を使ったデータ作成」と判断してください。

なお、本コンペにおける「LLM」とは、言語を出力とするモデル全般とし、いわゆる言語モデルであっても言語を出力としないものはこれに含まれないものとします。

### LLMを用いてないデータ作成の例

- データのクリーニング:
  - 正規表現やスクリプトを用いて以下のようなことをする。
    - 不要な文字の削除
    - フォーマットの統一
    - 重複排除
- 人手による修正:
  - 誤字脱字の修正や、人間が内容を確認して行うアノテーション。
- 非生成的なデータ拡張:
  - 類義語辞書（WordNet等）を用いた単語の置換、ランダムなノイズ付与など、LLMの推論能力に依存しない従来のデータ拡張手法
- 本ドキュメントで述べているLLMの定義から外れるモデル(BERT、RoBERTa、DeBERTa等のエンコーダモデル)を使ったテキスト処理

### LLMを用いたデータ作成(合成)の例

- OpenAI GPTシリーズ、Claude、Gemini、Llama等の生成AIモデル(APIおよびローカルモデルを含む)を使用して、新たなテキストデータを生成すること
- LLMを使用して、既存のテキストを言い換え（Rephrasing）したり、要約したりすること
- LLMの出力を教師データとして学習に使用すること

このように、ポイントは

「データを構築するプロセスにおいて、直接的にLLMが作成データに関与しているか」となります。

LLMを用いてない例は、ルールベース処理(正規表現、文字列操作、テンプレート処理)だったり、人手による作成(自ら記述や人手によるラベル付け、アノテーション)です。

LLMを用いたデータ作成(データ合成)の例は、LLMの重み(API、ローカル問わず)を利用して、LLMにテキストを生成させたり、識別させたりしています。

FAQ（よくある質問）

Q. データの前処理にChatGPTやCodexなどを使ってコードを書かせ、そのコードでデータを処理するのはOKですか？

A. 可能です。「データを処理するコード」をLLMに書かせることは補助的な利用とみなされ許可します。ただし、LLMそのものに「データの中身」を作らせたり書き換えさせたりすることは禁止です。

Q. データの品質チェック（フィルタリング）にLLMを使うのは？

A. 禁止です。「このデータは高品質か？」という判定をLLMに行わせ、その結果選別されたデータセットを使うことは、「LLMの知識を利用したデータセット構築」に該当するため禁止します。

また、昨今は翻訳にLLMを用いたものも多く登場していますが、これらを使って表現の違うテキストを得ることもある種の合成です。

(本コンペではLLM翻訳、非LLM翻訳含めて一律禁止にしています> 8.開発におけるツールの扱い)

## LLMモデル開発におけるお約束

### 評価データを学習に使うのはやめましょう。

これから試す対象であるベンチマークのデータ、評価データを学習することはカンニングしているようなものです。これではベンチマークに対してモデルが優秀なのかどうか計ることができません。これを「データリーク」や「汚染(Contamination)」と呼びます

### ベンチマークのデータを学習するのはやめましょう

メインコンペについては運営が指定したデータのみ使用してもらいますが、アドバンスドコンペは参加者に皆さんがライセンス的に問題ないデータを自由に選んでもらえます。しかし、ベンチマークで使われているデータを使用するのはやめましょう。

ベンチマークで使用しているデータを意図せず使用されて、評価用のデータがトレーニングデータの一部と重複していた場合、モデルが単にデータを「記憶」しているだけにもかかわらず、その性能が過剰に評価される可能性があります。これもContaminationにあたります。

「今回試す対象のベンチマークでないから良いのでは」と思われるかもしれませんが、避けた方が無難です。

### 評価データを過剰に意識したデータ作成は避けましょう

基本的にモデル開発コンペティションは、モデルの汎化性能を適正に評価することを目的としています。そのため、評価データ(テストデータ)の統計的特徴を分析し、それに過剰に適合させた学習データを作成する行為は、データリークに近い行為と考えられ、避けた方が無難です。

過度な分析の禁止:

評価データの目視確認、テキストマイニング、分布分析などを行い、評価データの傾向（トピック、文体、キーワード分布など）を逆算・特定する行為は避けてください。

最適化の制限:

上記の分析結果に基づき、評価データに酷似した学習データを意図的に作成・選別することは、モデルの実用的な評価を損なうため控えてください。

許容範囲:

フォーマットの確認など、最低限のデータ確認は許容されますが、あくまで「未知のデータ」として扱うという原則を遵守してください。